



Clasificación de Días con Alta Volatilidad en el Mercado Bursátil mediante Aprendizaje Automatizado

Aprendizaje Automatizado 2025-2

Daniel Rojo Mata, Elizabeth Ríos Alvarado

2 de junio de 2025



Índice general

1 Introducción

► Introducción

► Metodología

► Resultados

► Discusión y Conclusiones



Motivación

1 Introducción

- El mercado bursátil presenta alta volatilidad, dificultando la toma de decisiones.
- Predecir la **volatilidad** —más que el precio— ayuda a gestionar riesgos.
- El aprendizaje automatizado ofrece herramientas eficaces para esta tarea.



Contexto del problema

1 Introducción

- La predicción bursátil es desafiante por factores no lineales y eventos externos.
- Métodos clásicos limitados para captar relaciones complejas.
- Nuevas soluciones con IA y Aprendizaje Automatizado.



Objetivo Principal

1 Introducción

- Diseñar un sistema capaz de **predecir días con alta volatilidad** en el mercado bursátil.
- Comparar el desempeño de **modelos clásicos** y de una **Red Neuronal Recurrente (RNN)** para evaluar el impacto de la memoria temporal en el modelado.
- Utilizar **técnicas de aprendizaje automatizado** para mejorar la detección de eventos críticos que afectan la toma de decisiones financieras.



Índice general

2 Metodología

► Introducción

► Metodología

► Resultados

► Discusión y Conclusiones



Procesamiento de Datos

2 Metodología

- Datos descargados vía **FinRL** (Yahoo Finance).
- Variables: precios, indicadores técnicos, VIX, turbulencia, día de la semana.



Etiquetado de Volatilidad

2 Metodología

- Se calcula la **desviación estándar móvil** de los rendimientos (ventana de 5 días) para cada acción.
- Se define un umbral dinámico usando el **percentil 70** por activo: días con volatilidad por encima de este umbral se etiquetan como 1.



Selección de Variables Financieras

2 Metodología

- Se evaluaron diferentes **subconjuntos de variables** para identificar cuáles aportan mayor valor predictivo:
 - Todas las variables disponibles.
 - Solo indicadores técnicos (e.g., RSI, MACD, Bollinger).
 - Solo precios (open, high, low, close).
 - Solo VIX y turbulencia del mercado.
- Evaluación en modelos clásicos: XGBoost, RF, SVM, KNN, Regresión Logística.



Selección de Variables Financieras

2 Metodología

- Se implementó un **algoritmo genético** para seleccionar combinaciones óptimas de variables que maximizan el F1-score.
- Este análisis permite identificar qué variables financieras son más relevantes para anticipar eventos de alta volatilidad.
- La ganadora: **Todas las variables**



Selección de Variables Financieras

2 Metodología

- Mejor resultado con **todas las variables**: F1-score 0.6484.
- Peor resultado: solo precios ($F1 = 0.0769$).
- Algoritmo genético seleccionó subconjuntos compactos ($F1 = 0.4091$).



Modelos Implementados

2 Metodología

- **Modelos clásicos de clasificación:**
 - XGBoost, Random Forest, SVM, KNN, Regresión Logística.
 - Se evaluaron con y sin memoria explícita (columnas desfasadas).
- **Red Neuronal Recurrente (LSTM):**
 - Entrenada con secuencias de 15 días para capturar dinámica temporal.
 - Comparación entre versión estándar y versión con **pesos de clase** para corregir desbalance.
 - Se exploraron distintos **umbrales de decisión** para convertir probabilidades en clases.



Índice general

3 Resultados

► Introducción

► Metodología

► Resultados

► Discusión y Conclusiones



Modelos clásicos

3 Resultados




Figura: Métricas en los métodos clásicos



Modelos clásicos con memoria

3 Resultados




Figura: Métricas en el método concurrente



Red Neuronal Recurrente

3 Resultados




Figura: Métricas en RNN



Índice general

4 Discusión y Conclusiones

- ▶ Introducción
- ▶ Metodología
- ▶ Resultados
- ▶ Discusión y Conclusiones



Discusión

4 Discusión y Conclusiones

- XGBoost superó al resto de los modelos clásicos en todas las métricas.
- Incorporar **memoria con lags** mejora el rendimiento sin aumentar la complejidad estructural.
- La RNN detectó todos los días de alta volatilidad ($\text{recall} = 1.0$), pero con baja precisión.
- Los falsos positivos de la RNN pueden ser útiles como alertas tempranas, dependiendo del contexto de aplicación.



Conclusiones

4 Discusión y Conclusiones

- Los modelos clásicos con memoria implícita (XGBoost, RF) ofrecieron el mejor rendimiento global.
- La RNN con LSTM es útil cuando el costo de ignorar eventos críticos es alto.
- Incorporar múltiples fuentes de datos y memoria temporal mejora la capacidad predictiva.



¡Gracias por su atención!