

Clasificación de Días con Alta Volatilidad en el Mercado Bursátil mediante Aprendizaje Automatizado

Elizabeth Ríos Alvarado, Daniel Rojo Mata

Posgrado en Ciencia e Ingeniería de la Computación

Abstract

Este trabajo aborda la predicción de días con alta volatilidad en el mercado bursátil mediante técnicas de aprendizaje automatizado. Para ello, se construyó un conjunto de datos con indicadores técnicos, precios históricos, medidas de sentimiento del mercado (VIX y turbulencia) y el día de la semana. La volatilidad fue estimada a través de una ventana móvil de cinco días y etiquetada utilizando un umbral dinámico basado en percentiles, adaptado a cada activo.

Se evaluó el desempeño de diversos modelos clásicos de clasificación, como *Random Forest*, *XGBoost*, *SVM*, *KNN* y regresión logística, utilizando el *F1-score* como métrica principal. Se realizó un análisis empírico sobre el impacto de diferentes subconjuntos de variables. Los resultados mostraron que el uso combinado de toda la información disponible ofrece el mejor rendimiento predictivo.

Como estrategia para incorporar memoria temporal en modelos clásicos, se incluyeron columnas desfasadas con información histórica reciente. Además, se implementó una red neuronal recurrente (*RNN* tipo *LSTM*) para modelar directamente la dependencia temporal en las series. Esta red, ajustada con pesos de clase y umbrales personalizados, alcanzó un *recall* del 100% para la clase minoritaria, con un *F1-score* competitivo frente a los modelos tradicionales. En conjunto, los hallazgos resaltan el valor de enfoques híbridos y secuenciales para la detección temprana de eventos críticos en contextos financieros.

1 Introducción

El mercado bursátil es un mundo muy complejo en el cual el precio de las acciones fluctúa rápidamente, lo cual hace difícil predecir lo que podría pasar incluso de un día para otro. A diferencia de la predicción directa de precios, anticipar la volatilidad permite gestionar mejor el riesgo y tomar decisiones estratégicas con mayor anticipación, lo cual es especialmente valioso para inversionistas, instituciones financieras y diseñadores de algoritmos de trading.

Por otra parte, el Aprendizaje Automatizado brinda herramientas valiosas para afrontar este tipo de problemas difíciles. En particular, ha mostrado avances significativos en tareas de clasificación y predicción en finanzas, con modelos que van desde árboles de decisión y regresión logística hasta arquitecturas más complejas como redes neuronales profundas y redes recurrentes. Una ventaja clave de estos modelos es su capacidad para integrar múltiples fuentes de información —como precios, indicadores técnicos y señales externas como el VIX o la turbulencia del mercado—

y adaptarse a patrones temporales, ya sea mediante variables con desfase (*lags*) o estructuras secuenciales como *LSTM*.

Este trabajo aborda el problema de identificar días con alta volatilidad a partir de un enfoque experimental e híbrido. Para ello, se construyó un conjunto de datos enriquecido con información técnica y contextual, y se aplicaron modelos clásicos de clasificación, así como una red neuronal recurrente tipo *LSTM*. Se evalúa la importancia de distintos conjuntos de variables sobre el desempeño predictivo, y se exploran estrategias como el ajuste de pesos por clase y la selección de umbrales para mejorar el desempeño frente a clases desbalanceadas.

2 Antecedentes

La predicción de los precios de las acciones en los mercados financieros representa un desafío constante para analistas, inversionistas e instituciones, debido a la multiplicidad de factores que influyen en su comportamiento. Entre ellos se encuentran indicadores

económicos, eventos geopolíticos y, en particular, la psicología colectiva del mercado. Además, los valores de las acciones (*stocks*) suelen presentar una alta volatilidad, con fluctuaciones que siguen patrones no lineales y en muchos casos erráticos, lo cual incrementa significativamente la complejidad de cualquier intento de predicción.

Por décadas, se han utilizado modelos estadísticos, así como series de tiempo, análisis fundamentales y análisis técnicos para poder hacer las predicciones; pese a ello, estos métodos son muy limitados para poder ajustar las relaciones no lineales existentes en las acciones, pues están lejos de ser representadas mediante modelos puramente lineales.

Los precios de las acciones están sujetos a una cantidad relevante de volatilidad, lo que dificulta la predicción incluso cuando las tendencias parecen ser claras. Esta volatilidad plantea un reto para los métodos tradicionales que a menudo suponen que los precios futuros seguirán un patrón predecible basado en observaciones anteriores (datos históricos).

No obstante, en los años recientes, y gracias al auge de la *Inteligencia Artificial* (IA), han emergido nuevos métodos y modelos para hacer predicciones en el mercado financiero. Estos modelos pueden identificar patrones y correlaciones que no son evidentes mediante enfoques estadísticos tradicionales.

2.1 Revisión de literatura

Se ha observado que muchos estudios sobre el mercado de valores utilizan algoritmos de *Machine Learning* (ML). De acuerdo con una revisión sistemática de revisiones realizada por [Lin et al. \(2024\)](#), algunos de los métodos más comunes aplicados en la predicción bursátil incluyen:

- **Redes Neuronales (NN):** utilizadas por su capacidad para modelar relaciones no lineales complejas. Entre ellas se incluyen ANN, RNN y CNN. Aproximadamente el 33% de los estudios analizados las utilizan.
- **Redes LSTM (Long Short-Term Memory):** variantes de las RNN diseñadas para capturar dependencias a largo plazo en series temporales. Destacan en estudios que abordan predicción secuencial.
- **Support Vector Machines (SVM):** métodos supervisados clásicos, eficaces en problemas de

clasificación y regresión. Representan una proporción destacada en estudios comparativos.

- **Técnicas clásicas de ML:** como *Random Forest*, *Decision Trees* y *k-Nearest Neighbors* siguen siendo utilizadas, especialmente en estudios exploratorios y como líneas base.

Estos métodos han demostrado ser herramientas efectivas para modelar el comportamiento financiero de los mercados, y proporcionan un marco robusto sobre el cual construir nuevas propuestas metodológicas.

3 Metodología

El trabajo consistió en desarrollar un sistema de clasificación binaria para identificar días de alta volatilidad en el mercado financiero utilizando datos históricos de acciones e indicadores técnicos. A continuación, se describe la metodología empleada.

3.1 Obtención y Procesamiento de Datos

Se utilizó la biblioteca FinRL para descargar datos históricos desde Yahoo Finance. Se seleccionaron múltiples acciones del índice S&P500, tales como *Apple*, *Nvidia*, *Amazon*, etc., y se extrajeron precios diarios junto con el índice de volatilidad VIX y la turbulencia del mercado.

Posteriormente, se aplicó una serie de transformaciones mediante ingeniería de características, incluyendo indicadores técnicos como MACD, RSI, CCI, bandas de Bollinger, promedios móviles, entre otros.

3.2 Cálculo y Etiquetado de Volatilidad

Se calculó la volatilidad diaria por acción como la desviación estándar móvil de 5 días de los rendimientos porcentuales diarios. A fin de generar una etiqueta binaria (*volatilidad_alta*), se utilizó un umbral basado en el percentil 70 por acción. Esto permitió adaptar el umbral a la naturaleza de cada activo y obtener una clase positiva representando aproximadamente el 30% de los datos.

3.3 Incorporación de memoria temporal en modelos clásicos

Para beneficiar la representación de los datos y permitir que los modelos clásicos pudieran tener acceso a información del pasado, se incorporaron columnas con desfase temporal (también conocidas como *lags*).

Estas columnas representan los valores históricos de ciertas variables clave, como los rendimientos diarios y la volatilidad móvil, en días anteriores. Por ejemplo, se añadieron variables como `return_t-1`, `return_t-2`, ..., `volatility_5d_t-5`, lo cual permitió que cada observación (día) contuviera un resumen explícito de lo que ocurrió en los días previos.

Esta técnica permite introducir **memoria implícita** en los modelos de clasificación tradicionales como *Random Forest*, *XGBoost*, *SVM* y *Regresión Logística*, sin requerir arquitecturas secuenciales. De esta forma, el modelo puede aprender patrones temporales cortos sin necesidad de recurrir a redes neuronales.

Este enfoque también mantiene la compatibilidad con los pipelines de entrenamiento clásicos y facilita el análisis interpretativo, permitiendo evaluar directamente la importancia de las variables con desfase.

3.4 Evaluación Empírica de Conjuntos de Variables

Se condujo un estudio empírico para evaluar el impacto de distintos subconjuntos de características sobre el desempeño del modelo.

Para esta evaluación empírica se usaron modelos clásicos de clasificación tales como **Random Forest**, **Regresión Logística**, **XGBoost**, **SVM** y **K-Nearest Neighbors**. Se calculó el **F1-score** promedio en cada caso para ser usado como una métrica comparativa para los subgrupos anteriores. Finalmente, se implementó un algoritmo genético para buscar combinaciones óptimas de características, concluyendo que el uso de todas las variables disponibles producía los mejores resultados.

3.5 Implementación de Red Neuronal Recurrente (RNN)

Finalmente, se entrenó una Red Neuronal Recurrente (RNN) utilizando una arquitectura con capas LSTM y utilizando el conjunto de indicadores financieros con mejor valor en *F1 – score* obtenido en la evaluación empírica. El objetivo fue capturar relaciones temporales entre secuencias de días. El modelo se evaluó tanto con como sin pesos de clase, dado el desbalance de la clase positiva. Se ajustó el umbral de decisión para maximizar el F1-score, seleccionando el valor óptimo empíricamente.

3.6 Métricas de Evaluación

Los modelos fueron evaluados principalmente usando el F1-score debido al desbalance entre clases. También se reportaron precisión, exhaustividad (recall) y el área bajo la curva ROC (AUC-ROC) para un análisis más completo del desempeño.

4 Experimentos y resultados

A continuación, se presentan los experimentos realizados para evaluar la capacidad de diferentes modelos y conjuntos de variables en la predicción de días con alta volatilidad.

4.1 Evaluación de Conjuntos de Variables

Se evaluaron distintos conjuntos de características para determinar cuáles ofrecen mejor capacidad predictiva en la tarea de clasificación de días con alta volatilidad. A continuación, se resumen los conjuntos utilizados:

- **Todas las variables:** combinación completa de indicadores técnicos, precios, VIX, turbulencia y día de la semana.
- **Indicadores técnicos:** MACD, RSI, CCI, bandas de Bollinger, promedios móviles, entre otros.
- **Solo precios:** precios de apertura, cierre, máximos y mínimos.
- **VIX y Turbulence:** indicadores de sentimiento y volatilidad del mercado.

Los resultados obtenidos (F1-score promedio) fueron los siguientes:

- **Todas las variables:** 0.6484
- **Indicadores técnicos:** 0.2834
- **Solo precios:** 0.0769
- **VIX + Turbulence:** 0.2610

Estos resultados muestran que el uso de **toda la información disponible** proporciona un desempeño significativamente superior frente al uso de subconjuntos aislados. Esto se debe probablemente a que la interacción entre distintos tipos de variables (técnicas, de precios y de contexto) aporta señales complementarias útiles para la clasificación.

Además, se realizó un experimento de selección de variables mediante un algoritmo genético, con el objetivo de encontrar subconjuntos más compactos que

mantuvieran un buen rendimiento. En una ejecución representativa del algoritmo (100 generaciones, población de 50 individuos), se alcanzó un F1-score promedio de **0.4091**, seleccionando las siguientes variables:

```
[ 'close', 'low', 'volume', 'boll_ub',
  'boll_lb', 'rsi_30', 'cci_30', 'dx_30',
  'turbulence' ]
```

Si bien este subconjunto no supera a la combinación completa en desempeño, representa una alternativa más ligera y eficiente, con resultados competitivos. Es importante notar que, debido a la naturaleza estocástica del algoritmo, distintos experimentos pueden producir conjuntos levemente distintos, pero con rendimientos similares. Esto sugiere que las variables seleccionadas de forma repetida en diferentes ejecuciones podrían considerarse especialmente relevantes.

El uso del algoritmo genético solo refuerza el hecho, empíricamente, de que el mejor conjunto de atributos con los cuales se debe trabajar es **Todas las variables**, los cuales son:

```
[ 'open', 'close', 'high', 'low', 'volume',
  'macd', 'boll_ub', 'boll_lb', 'rsi_30',
  'cci_30', 'dx_30', 'close_30_sma',
  'close_60_sma', 'vix', 'turbulence', 'day' ]
```

4.2 Clasificadores Clásicos

Los modelos clásicos fueron evaluados en un conjunto de prueba separado. En general, **XGBoost** y **Random Forest** fueron los que mejor rendimiento obtuvieron, alcanzando *F1-scores* promedios superiores al resto. **K-Nearest Neighbors (KNN)** mostró un desempeño débil frente al desbalance de clases, mientras que la **Regresión Logística** sirvió como línea base aceptable.




Figure 1. Métricas en los métodos clásicos

4.3 Clasificadores con Recurrencia

La primera solución para incorporar memoria fue agregar **atributos históricos** directamente al conjunto de datos. Esta técnica permitió que los modelos tradicionales “miraran hacia atrás” sin alterar su estructura interna.

Se incluyeron variables como:

- Rendimientos rezagados: `return_t-1`, `return_t-2`, ..., `return_t-5`
- Volatilidad móvil histórica: `volatility_5d_t-1`, ..., `volatility_5d_t-5`
- Indicadores técnicos desfasados, como `rsi_30_t-1` o medias móviles pasadas

Esta estrategia mejoró significativamente el desempeño de algunos clasificadores, especialmente **XGBoost**, al proporcionar contexto adicional sobre el comportamiento reciente del activo financiero. De esta manera, el modelo pudo capturar tendencias de volatilidad sin requerir arquitecturas secuenciales.




Figure 2. Métricas en los métodos recurrentes

4.4 Red Neuronal Recurrente (RNN)

Sabiendo que la mejor combinación de características es con todos los indicadores financieros, se entrenó una RNN con capas LSTM utilizando secuencias de 15 días como entrada. Se compararon dos configuraciones:

- **Sin pesos de clase:** el modelo favoreció la clase mayoritaria (baja volatilidad), obteniendo alta precisión general pero pobre sensibilidad (recall) para la clase minoritaria.
- **Con pesos de clase:** se ajustaron los pesos inversamente proporcionales a la frecuencia de cada clase. Esto permitió detectar todos los días de alta volatilidad (`recall = 1.0`), mejorando sustancialmente el F1-score, aunque con menor precisión global.

Además, se aplicó una búsqueda empírica del umbral de decisión que maximizara el F1-score, encontrando que umbrales bajos (0.05 – 0.10) ofrecían mejor balance entre precisión y recuperación de eventos relevantes.




Figure 3. Métricas en las RNN

4.5 Discusión

Se desarrolló un sistema para predecir días con alta volatilidad en el mercado financiero, combinando ingeniería de características, modelos clásicos de clasificación y redes neuronales recurrentes (RNN). El objetivo fue identificar con anticipación eventos de alta volatilidad que pudieran representar riesgos o oportunidades para los inversionistas.

1) Etiquetado adaptativo del objetivo

El primer paso fue construir una etiqueta binaria de volatilidad a partir de la desviación estándar móvil de los rendimientos diarios. Para ello, se utilizó un **percentil dinámico (70)** que permitiera capturar contextos específicos por acción. Esto convirtió el problema en una **tarea de clasificación desbalanceada**, con pocos días etiquetados como altamente volátiles.

2) Estudio de variables útiles

Una de las preguntas clave fue: *¿Qué variables financieras son más útiles para predecir la volatilidad?*

Para responderla, se agruparon las variables en cuatro conjuntos: (1) todas las variables, (2) solo indicadores técnicos, (3) solo precios, y (4) solo VIX y turbulencia. Se entrenaron modelos clásicos como Random Forest y XGBoost con cada conjunto, y se observó que el uso de **todas las variables** dio los mejores re-

sultados (**F1-score de 0.6484**), mientras que usar solo precios produjo un desempeño muy pobre (**0.0769**). Esto sugiere que la combinación de distintas fuentes de información es importante para capturar adecuadamente las condiciones del mercado.

3) Optimización de subconjuntos con algoritmo genético

Para explorar combinaciones eficientes de variables, se implementó un **algoritmo genético** que buscó subconjuntos con alto desempeño. En una ejecución, se obtuvo un F1-score de **0.4091**, seleccionando variables como close, low, boll_ub, rsi_30, y turbulence. Aunque inferior al uso del conjunto completo, esta estrategia mostró que **múltiples combinaciones pueden ser efectivas**, y que existe una **robustez estructural** en los patrones que explican la volatilidad.

4) Incorporación de memoria explícita

Una limitación de los modelos tradicionales es que tratan cada fila como una observación independiente, ignorando las dependencias temporales entre días consecutivos. Para mitigar esto, se propuso una estrategia de **memoria explícita**, agregando columnas con datos rezagados:

- Rendimientos anteriores: return_t-1, return_t-2, ...
- Volatilidad móvil rezagada
- Indicadores técnicos desfasados

Esto permitió que modelos como XGBoost **mejoraran su desempeño** incorporaran contexto histórico sin cambiar su arquitectura. Esta técnica es simple, efectiva y fácilmente integrable a modelos tabulares.

5) Desempeño de modelos clásicos

En el conjunto de prueba, **XGBoost** resultó ser el modelo más efectivo:

- Mayor **F1-score (0.7700)**
- Alta **precisión (0.7938)** y **recall (0.7476)**
- Excelente **AUC-ROC (0.9213)**

Random Forest también mostró desempeño competitivo (**F1-score 0.7368**, **AUC-ROC 0.9233**). Otros modelos como SVM y KNN presentaron precisión elevada pero bajo recall, lo que los hace menos útiles para detectar eventos críticos de volatilidad.

6) Uso de modelos secuenciales: Red Neuronal Recurrente (RNN)

Para capturar dependencias temporales de forma directa, se implementó una RNN con ventanas de 15 días. Se entrenaron dos versiones:

- **RNN estándar:** sin ajuste por desbalance.
- **RNN con pesos de clase:** para penalizar errores en la clase minoritaria.

La versión ponderada alcanzó un **recall de 1.00**, lo que implica que detectó todos los días con alta volatilidad. Aunque la precisión fue baja, el **F1-score alcanzó 0.4586**, lo cual puede ser valioso en escenarios donde **los falsos negativos tienen un costo alto**. Además, se experimentó con distintos **umbrales de decisión** (por ejemplo, 0.05), lo cual mejoró la capacidad de detección del modelo al adaptarse a la distribución real de probabilidades.

En resumen, los hallazgos más importantes del estudio son:

- **XGBoost** es el modelo clásico más efectivo para predecir volatilidad en contextos desbalanceados.
- La combinación de variables de precios, indicadores y contexto mejora notablemente el rendimiento predictivo.
- La incorporación de **memoria histórica**, ya sea con columnas desfasadas o con modelos secuenciales como RNN, permite detectar mejor los patrones temporales que preceden a eventos volátiles.
- Ajustar **pesos de clase** y **umbrales de decisión** son técnicas clave para mejorar el balance entre sensibilidad y precisión en contextos críticos.

Estos resultados son especialmente útiles para la construcción de sistemas de alerta temprana en finanzas, donde detectar eventos de alta volatilidad a tiempo puede ser más importante que evitar falsas alarmas.

5 Conclusiones

Este trabajo abordó la predicción de eventos de alta volatilidad en el mercado bursátil mediante un enfoque dual: modelos clásicos de clasificación con memoria implícita e integración de variables desfasadas, y redes neuronales recurrentes (RNN) con arquitectura LSTM para capturar directamente dependencias temporales.

Los resultados muestran que los modelos clásicos, particularmente XGBoost, ofrecen un desempeño altamente competitivo. Con un F1-score de 0.7700, un

recall del 74.76% y un AUC-ROC de 0.9213, este modelo logra un equilibrio adecuado entre precisión y sensibilidad, lo que lo hace una excelente opción para esta tarea.

Por otro lado, la RNN con LSTM, aun sin alcanzar métricas globales tan altas, fue capaz de detectar todos los eventos de alta volatilidad en el conjunto de prueba (recall = 1.0000), tanto con como sin pesos de clase. Sin embargo, esta capacidad vino acompañada de una pérdida importante de precisión (aprox. 29.6%) y una caída considerable en el AUC-ROC (0.5341 sin pesos y 0.5693 con pesos). El F1-score se mantuvo en 0.4566, indicando que, aunque la red identifica correctamente todos los eventos críticos, también genera muchos falsos positivos.

Los modelos clásicos como XGBoost y Random Forest destacan por su rendimiento global, interpretabilidad y estabilidad, mientras que la RNN muestra potencial como herramienta de alerta temprana, útil cuando el costo de pasar por alto un evento crítico es alto. La combinación de ambos enfoques podría ser una línea prometedora para aplicaciones reales: utilizar un modelo secuencial como filtro inicial, y confirmar con un clasificador más preciso.

Creemos que la mejor opción en este caso fue usar los modelos clásicos con memoria implícita porque fueron mucho más sencillos de programar y dieron mejores resultados.

References

Lin, Chih-Yang and João A. L. Marques (2024). "Stock market prediction using artificial intelligence: A systematic review of systematic reviews". In: *Social Sciences Humanities Open* 9, p. 100864. DOI: 10.1016/j.ssaho.2024.100864.

Liu, Yuwei et al. (2020). *FinRL: Deep Reinforcement Learning Framework to Automate Trading in Quantitative Finance*. <https://github.com/AI4Finance-Foundation/FinRL>. Accedido: mayo 2025.

Minshall's Finance (n.d.). *Educational videos on algorithmic trading and FinRL*. <https://www.youtube.com/@minshallsFi>. Accedido: mayo 2025.